

Gestión Unificada de Consultas Inteligentes

Descripción

Actualmente en la empresa MineTech se dispone de operadores de soporte técnico que reciben consultas de clientes y de operadores de campo. Los operadores de soporte técnico van rotando por turnos y cada uno recibe las consultas en el turno que le corresponde a través de WhatsApp. El problema es que algunos clientes mantienen el contacto del soporte técnico y le realizan consultas aunque este no se encuentre fuera de su horario de turno. Lo que acarrea el inconveniente de molestar al empleado fuera de su horario, no pudiendo atender la consulta porque se encuentra fuera del alcance de la documentación, debiendo el operario derivar la consulta a quien corresponda. Esto genera retrasos e inconvenientes y faltas en la calidad de servicio, porque los empleados fuera de su horario de turno están indispuestos a la atención del cliente perdiendo la consulta.

Se especifica que sería deseable que los clientes y operadores de campo tengan un único punto de entrada (número de WhatsApp o Aplicación) para las consultas, y que el sistema derive la consulta a quien corresponda. Además que el sistema mismo sea capaz de resolver consultas simples a partir de una base de conocimiento formada por la documentación del equipamiento y procedimientos de la empresa.

Lo que se solicita es implementar un sistema completo de gestión de soporte, con validación, automatización, auditoría y derivación inteligente.

Objetivo

Centralizar todas las solicitudes de soporte a un único número de WhatsApp, automatizar las respuestas cuando sea posible y derivar al operador de turno cuando no lo sea, sin que el cliente note el cambio. Además validar al cliente y registrar cada interacción con fines de auditoría y mejora continua.

Resumen Ejecutivo

- **Costo de implementación:** USD 1.200,00
- **Costo mensual del sistema:** USD 20,00

- **Soporte y mantenimiento mensual:** USD 80,00
- **Tiempo de implementación:** 3-8 semanas
- **Beneficios:**
 - Un único número de WhatsApp
 - Automatización con IA
 - Derivación transparente al operador
 - Auditoría completa
 - Reducción estimada del 40–60% de carga operativa
 - Sistema escalable y sin dependencia de técnicos internos

Arquitectura Propuesta

1) Punto único de entrada

Un único número de WhatsApp Business API (Meta Cloud API) al que se comunican tanto los clientes como los operadores de campo. Todos los mensajes ingresan por ese mismo número y nunca directo al operador. La principal ventaja es la eliminación del contacto directo con los técnicos.

2) Capa de Orquestación (Gateway)

Un servicio de backend, basado en una solución específicamente diseñada para este efecto (usando tecnología Node.js + n8n) cuya función sea:

- Recibir los mensajes entrantes de WhatsApp
- Identificar al cliente
- Validar si el cliente está habilitado
- Responder a la consulta o derivar al operador
- Registrar la comunicación

Este servicio es el cerebro del sistema.

3) Validación del cliente

Antes de responder:

- Verificar número en base de clientes.
- Verificar estado (activo, moroso, suspendido, etc.).
- Registrar datos del dispositivo, horario, etc.

Si no está validado:

- Solicitar DNI, CUIT o ID interno.
- Validar automáticamente.
- Registrar auditoría.

4) Motor de Respuestas Automáticas

En esta capa se encuentra la base documental para generar las respuestas automáticas.

Opciones técnicas

- Vector DB + embeddings (Pinecone, Qdrant, Chroma).
- Modelo LLM (Copilot Studio, Azure OpenAI, Claude API, etc.).
- Búsqueda semántica sobre la documentación.

Flujo

1. El cliente pregunta.
2. El sistema busca en la documentación.
3. Si encuentra una respuesta con confianza alta → responde automáticamente.
4. Si la confianza es baja → deriva al operador.

Resultado: automatización sin riesgo de respuestas incorrectas.

5) Derivación al operador de turno

El sistema debe:

- Saber quién está de turno (tabla Turnos).
- Enviar la consulta al operador por:
 - WhatsApp interno,
 - Telegram,
 - App interna,
 - Panel web,
 - o cualquier canal que elijas.

El cliente nunca ve el número del operador.

El operador responde desde su panel o WhatsApp interno, y el sistema reenvía la respuesta al cliente.

6) Auditoría completa

Registrar:

- Cliente.
- Fecha/hora.
- Consulta.
- Respuesta automática o humana.
- Operador asignado.
- Tiempo de resolución.
- Archivos adjuntos.

- Clasificación del ticket.

Esto te permite métricas reales:

- Tiempo promedio de respuesta.
- Cantidad de consultas por cliente.
- Temas más frecuentes.
- Eficiencia del soporte.

Flujo Completo

1. Cliente escribe al número único.
2. Backend recibe el mensaje.
 - Un Webhook de n8n recibe el mensaje
 - i. Datos del cliente
 - ii. Mensaje
 - iii. Archivos
 - iv. Marca de tiempo
3. Valida al cliente.
 - n8n consulta a través de Node.js a una base en PostgreSQL
 - si está validado continúa
 - si no está validado solicita datos para su validación
4. Registra auditoría.
 - n8n registra la información en la base de datos
5. Analiza la intención.
6. Busca respuesta automática:
 - n8n + Vector DB
 - i. realiza la búsqueda semántica usando Chroma
 - ii. con los fragmentos relevantes arma el prompt y consulta al LLM
 - Si existe y es confiable → responde.
 - Si no → deriva al operador de turno.
 - i. identifica al operador disponible según la tabla de turnos
 - ii. y envía la consulta por WhatsApp interno o panel web
7. El Operador responde desde su panel.
8. El sistema reenvía la respuesta al cliente.
9. Todo queda auditado.

Tecnologías recomendadas

Sin compromiso permanente, es decir que cualquiera de ellas puede cambiarse en caso de ser necesario.

Backend

- Node.js (Express)

WhatsApp

- Meta Cloud API (oficial, recomendada)
- Twilio WhatsApp API (alternativa)

Motor de IA

- Azure OpenAI (Copilot)
- Anthropic Claude
- OpenAI GPT-4o
- Llama 3.1 local (sin costo)

Vector DB

- Pinecone
- Qdrant
- ChromaDB (open source)

Panel del operador

Web simple en React con Material Components

Ventajas

- Se elimina el contacto directo con los técnicos.
- Respuestas automáticas reducen la carga operativa.
- Auditoría completa para control interno.
- Escalable a múltiples operadores.
- Transparente para el cliente.
- Profesional y alineado a estándares modernos.

Servicios a Contratar

1 - WhatsApp Business API (Meta Cloud API)

Obligatorio

Necesario para tener un único número oficial.

- No se necesita Twilio ni proveedores externos.
- Meta cobra por conversación, no por mensaje.
- En Argentina, el costo típico es bajo para casos de soporte.

2 - Hosting para backend

Obligatorio porque la empresa no dispone de data center propio

Recomendado por costo/beneficio. Hetzner CX23 (4GB RAM)

- Costo aproximado: USD 5–8/mes.
- Permite la instalación de:
 - n8n
 - PostgreSQL
 - microservicio de IA Node.js
 - vector DB
 - SSL

3 - DNS

Obligatorio por motivos de seguridad, es necesario para el SSL

Son dos componentes:

- el servidor de DNS
- el servicio de nombre de dominio.

Puede ser sin costo si se utiliza el mismo que provee el DNS del hosting del sitio web

Por ejemplo: <https://soporte.minetech.com.ar/>

4 - Base de datos

Obligatorio incluido en la implementación

PostgreSQL instalado en el mismo VPS.

Necesario para:

- Clientes
- Auditoría
- Turnos
- Operadores

5 - Motor de IA

Obligatorio

- GPT-4o mini, motor principal:
 - estable, excelente calidad,
 - provisto por OpenAI o Azure OpenAI
 - económico: USD 0.15 por millón de tokens
 - excelente integración con n8n
 - ideal para producción
- Groq + Llama 3.7 (8B/70B)
 - sin costo
 - para clasificación y fallback (si el servicio principal no está disponible)
- Qdrant + embeddings open-source: para RAG.
- Ollama: para realizar pruebas locales no recomendado en producción.

Costo Mensual

Servicio	Costo
VPS	USD 5–8/mes
Dominio .com	USD 10–12/año
Cloudflare DNS	0
WhatsApp Business API	USD 10
IA (GPT-4o mini)	USD 1–3/mes según uso
IA (Groq)	0
Backups	USD 1
Costo mensual servicios contratados	USD 20 (aprox)
Soporte y mantenimiento mensual	USD 80 (aprox)

El soporte y mantenimiento mensual incluye:

- Monitoreo del VPS
- Actualizaciones de n8n
- Actualizaciones de API
- Backups
- Ajustes del flujo
- Soporte ante fallas
- Ajustes de IA
- Ajuste de reglas de automatización

No incluye

- Nuevos flujos de trabajo
- Nuevas reglas de automatización

Implementación del Proyecto

Incluye:

- Arquitectura
- Desarrollo
- Configuración
- Puesta en marcha
- Documentación
- Capacitación
- Configuración del VPS
- Instalación de Docker
- Instalación de n8n
- Configuración de HTTPS (Let's Encrypt)
- Configuración de Cloudflare o DNS del sitio web
- Configuración de DNS o DNS del sitio web
- Instalación de PostgreSQL
- Instalación de Qdrant
- Creación de API interna
- Integración con WhatsApp Business API
- Creación del flujo completo en n8n
- Integración con IA (GPT-4o mini + Groq)
- Indexación de documentación
- Creación del panel del operador
- Pruebas end-to-end
- Capacitación al personal
- Documentación técnica

Detalle

Desarrollo de software

- API interna (Node.js) con endpoints para:
 - Validación de clientes
 - Gestión de turnos
 - Auditoría
 - Tickets
 - Operadores
 - Logs
- Base de datos PostgreSQL con todas las tablas:
 - clientes
 - operadores
 - turnos
 - auditoría
 - tickets
 - logs

- Vector DB (Qdrant) + indexación de documentación
- Microservicio de embeddings y búsqueda semántica
- Integración con IA (GPT-4o mini + Groq)
- Panel del operador (web simple)
- Lógica de negocio completa

Desarrollo del flujo completo en n8n

- Recepción de mensajes desde WhatsApp
- Validación del cliente
- Auditoría de entrada
- Clasificación de intención con IA
- Búsqueda en documentación
- Decisión automática
- Respuesta automática
- Derivación al operador
- Auditoría de salida
- Cierre del ticket

Todo el flujo queda armado, probado y documentado.

Configuración de infraestructura

- Configuración del VPS (Hetzner)
- Instalación de Docker
- Instalación de n8n
- Instalación de PostgreSQL
- Instalación de Qdrant
- Configuración de firewall
- Configuración de backups
- Configuración de certificados SSL (Let's Encrypt)
- Configuración de reverse proxy Nginx

Configuración de DNS

- Configuración del dominio en Cloudflare o servidor web actual
- Configuración de registros A, CNAME, MX si hace falta
- Configuración de HTTPS automático
- Configuración de seguridad básica (WAF, rate limiting)

Integración con WhatsApp Business API

- Alta del número
- Configuración del Webhook
- Configuración de plantillas
- Pruebas de envío y recepción
- Validación de tokens

- Integración con n8n

Documentación

- Documentación técnica completa
- Manual de uso para operadores
- Manual de administración
- Diagrama de arquitectura
- Diagrama de flujo del sistema

Capacitación

- 1 sesión de capacitación para operadores
- 1 sesión de capacitación para administradores
- 1 sesión de capacitación para uso de n8n

No se incluye

- Hosting (lo paga la empresa, ~USD 6/mes)
- Dominio (USD 10/año)
- Créditos de IA (USD 1–3/mes)
- Conversaciones de WhatsApp (USD 5–20/mes)

Todo eso está en los **costos mensuales**, pero no en el desarrollo.